RQ4 Ablation: TRACE 설계별 정확도 기여

각 층위의 설계는 정확도에 얼마나 기여하는가 · TRACE(pilotA A2) · 2026-11-10 실험 · 의미, 실제 예시, 설정, 결과, 해석

1. RQ4는 무엇을 묻는가

Ablation(제거 실험)은 모델의 부품을 하나씩 빼거나 단순한 것으로 바꿔 보고, 정확도가 얼마나 떨어지는지 재는 실험입니다. 많이 떨어지면 그 부품이 성능에 중요하다는 근거가 되고, 거의 그대로이거나 오르면 정확도에는 기여하지 않는다는 뜻입니다.

논문 초안의 RQ4는 TRACE를 세 층위로 나눠, 각 층위의 설계가 정확도에 얼마나 기여하는지 묻습니다. 각 층위는 초안이 말한 세 가지 어려움(C1~C3)에 대응합니다.

층위	TRACE의 설계 (Idea)	해결하려는 어려움	RQ4에서 바꾸는 것
입력	Idea 1: 물리 기반 prior(USGS)와 흔들림 강도(PGV)를 함께 입력	C1 원인의 모호성: 같은 피해 건수가 흔들림 · 산사태 · 액상화 중 어디서 왔는지 모름	prior를 균등분포로 교체 / 흔들림 강도 항 제거
모델 구조	Idea 2: 음이항분포 카운트 모델 + 노출(인구 · 세대 수) offset	C2 집계 카운트의 특성: 지역 규모 차이가 크고 과분산이 있음	음이항을 포아송으로 교체 / 노출 offset 제거
학습	Idea 3: 여러 지진에 걸친 크로스이벤트 학습(파라미터 공유 + 과거 라벨 활용)	C3 적은 관측 수: 지진 하나에 시정촌이 수십 개뿐	예측할 지진 하나로만 학습

2. TRACE가 하는 일 (실제 예시: 홋카이도 아쓰마초)

TRACE는 시정촌마다 "산사태가 났는가", "액상화가 났는가"를 숨은 상태(잠재변수)로 두고, 실제로 집계된 피해 건수를 가장 잘 설명하는 상태를 확률로 계산합니다. 2018 홋카이도 이부리 지진의 아쓰마초(厚真町, 산사태 피해가 컸던 곳)를 예로 들면 이렇습니다.

2-1. 입력

입력	아쓰마초 값	쓰이는 곳
피해 건수 6채널	사망 · 중상 · 경상 · 전파 · 반파 · 일부파손	관측값 (모델이 설명해야 하는 것)
노출(E)	인명 3채널 = 인구 4,838 · 주택 3채널 = 일반세대 수 2,121	피해 건수의 규모 기준
흔들림(PGV)	44.64	흔들림 자체로 생기는 기본 피해
USGS 산사태 확률(시정촌 평균)	0.0071	산사태 사전확률(prior)
USGS 액상화 확률(시정촌 평균)	0.0316	액상화 사전확률(prior)

2-2. 사전확률 (prior): 피해를 보기 전, 이 시정촌에서 재해가 났을 확률

산사태 로짓 = log(USGS 확률) + log(시정촌 크기 k) + log(판독 범위 cov) + κ · (산지 비율)
액상화 로짓 = log(USGS 확률) + b + (log k − 학습 시정촌의 log k 평균)
사전확률 = sigmoid(로짓). 학습하는 것은 κ(산사태)와 b(액상화) 하나씩뿐

홋카이도를 빼고 학습한 회차의 실제 값입니다 (κ = 0.0028, b = 2.89).

시정촌	산사태 사전확률	액상화 사전확률
아쓰마초 (산지 많음)	0.986	0.680
도마코마이시 (항만 도시)	0.799	0.809

아쓰마초 산사태 예: log(0.0071) + 9.24 − 0.07 + 0.0028 × 0.98 = 4.23, sigmoid(4.23) = 0.986. USGS 확률은 "칸 하나가 무너질 확률"이라 작지만, 시정촌 안의 칸 수(k)를 반영하면 "시정촌 어딘가에서 한 곳이라도 날 확률"이 됩니다.

2-3. 피해 모델: 재해가 나면 피해가 얼마나 늘어나는가

기대 피해 μ = 노출 E × 피해율 λ
$\log \lambda$ = 채널 기본값 + 지진 절편 α_e + $\beta \cdot \log$ PGV + $\delta \cdot$ 목조 비율 + $\gamma_{LS} \cdot$ (산사태 났나) + $\gamma_{LQ} \cdot$ (액상화 났나)
실제 피해 건수 ~ 음이항분포(평균 μ, 과분산 ϕ)

숨은 상태는 (산사태, 액상화) 조합 4가지(둘 다 없음 · 산사태만 · 액상화만 · 둘 다)입니다. 상태마다 기대 피해 μ를 계산하고, 실제 피해 건수가 각 상태에서 얼마나 그럴듯한지(우도)를 사전확률과 곱해 정확히 합칩니다. 그 결과가 "피해를 보고 난 뒤 산사태가 났을 확률(사후확률)"이고, 이 값으로 AUC를 냅니다.

2-4. 학습: 여러 지진에서 함께 배움

채널 기본값, β, δ, γ, ϕ, κ, b는 학습 지진 전체가 공유합니다. 학습 지진의 산사태 라벨은 "이 시정촌은 산사태가 났다/안 났다"를 알려 주는 부분 관측으로 씁니다(액상화 라벨은 쓰지 않음). 새 지진에서는 공유 파라미터를 그대로 쓰고, 지진 절편 α_e 하나만 그 지진의 피해 건수로 맞춥니다(정답은 쓰지 않음).

3. 실험 설정

기준 모델	TRACE = pilotA A2 (코드: minji1217/pilotA 브랜치 followup4-lq-J-nolabels). seed 0, 3000 epoch, 학습률 0.02, γ 정규화 λ_γ = 10, κ 정규화 10
평가 방식	LOEO(Leave-One-Event-Out): DPM 있는 5개 지진(구마모토 · 오사카 · 홋카이도 · 후쿠시마 · 노토)을 하나씩 학습에서 빼고, 뺀 지진을 예측. DisasterNet과 같은 5개 지진으로 추론 · 채점. 예) ①의 홋카이도 회차는 나머지 8개 지진 378행으로 학습하고, 홋카이도 40행을 예측
기준 학습 두 가지	① 8개로 학습, 5개 추론: 뺀 지진 외 8개 지진 전부(DPM 없는 지진 4개 포함)로 학습. TRACE 기준값 0.855 ② 4개로 학습, 5개 추론: 뺀 지진 외 DPM 있는 4개 지진으로만 학습 (DisasterNet과 같은 지진만 쓰는 조건). TRACE 기준값 0.862
채점	지진 · 재해마다 AUC를 내고, 채점 시정촌 수로 가중평균. 정답이 한쪽뿐인 조합은 제외. 예측값은 α_e를 맞춘 사후확률. "DPM 있는 5개" = 구마모토 · 오사카 · 홋카이도 · 후쿠시마 · 노토 (산사태 49곳 · 액상화 151곳)
반복	pilotA는 무작위 요소가 없어(숨은 상태를 샘플링 없이 정확히 합산, 초기값 고정) 같은 설정이면 결과가 항상 같음. 그래서 설정마다 한 번씩만 실행
원칙	한 번에 하나만 바꾸고 나머지는 TRACE 그대로. pilotA 모델 코드는 고치지 않고, 입력이나 부품만 바꿔 끼우는 별도 스크립트로 실행. 같은 스크립트로 TRACE 그대로를 돌려 기존 값(0.855, 0.862)과 똑같이 나오는 것을 먼저 확인

4. 각 설정: 무엇을 바꿨고, 실제로 어떻게 달라지나

4-1. 입력: prior를 균등분포로 교체

확인하려는 것 물리 기반 사전확률이 원인 구분(C1)에 필요한가

바꾼 것 재해마다 모든 시정촌에 같은 사전확률 하나를 줌. 산사태와 액상화를 똑같이 처리. 그 값을 정하는 방식 세 가지를 모두 실행

방식	정하는 법	아쓰마초 산사태	도마코마이 산사태	아쓰마초 액상화	도마코마이 액상화
TRACE 원래	시정촌마다 계산	0.986	0.799	0.680	0.809
0.5 (본문 추천)	모든 시정촌 0.5로 고정 (났다 · 안 났다 반반)	0.5	0.5	0.5	0.5
평균	학습 시정촌들의 원래 사전확률(κ = 0, b = 0일 때)을 평균한 값으로 고정	0.673	0.673	0.042	0.042
학습	위 평균값에서 시작해 값 하나를 자료에서 학습	모든 시정촌이 같은 값 (학습으로 정해짐)			

평균 · 학습 값은 홋카이도를 뺀 회차 기준이며, 회차마다 학습 시정촌이 달라 조금씩 다릅니다. 구현: 사전확률 계산 부분을 상수를 돌려주는 것으로 바꿔 끼움.

결과: 전체 AUC 0.855에서 0.602로 −0.253 (0.5 방식). 평균 0.629, 학습 0.591로 세 방식 모두 크게 떨어짐. 4개로 학습 기준도 0.862에서 0.666 (−0.197).

해석: 가장 크게 떨어지는 축에 속함. 모든 시정촌이 같은 출발점이면, 피해 건수가 늘어난 이유가 산사태인지 액상화인지 가를 단서가 없음. 예를 들어 아쓰마초는 피해가 커도, 사전확률이 같으면 모델은 그 피해를 액상화에도 똑같이 돌릴 수 있음. 지진별로 보면 홋카이도 액상화가 0.913에서 0.345로 무너짐.

> **정정 기록**: 처음 돌린 "평균" 방식은 USGS 확률이 0인 시정촌(산사태 18곳) 때문에 로그 평균이 0이 되어, 산사태 사전확률이 모든 시정촌에서 거의 0(약 0.25%)으로 들어갔습니다. 산사태와 액상화가 다르게 처리된 셈이라, 계산 방식을 위 표처럼 고쳐 다시 돌렸습니다(그때 값 0.602는 폐기). 0.5 방식은 이 실수와 무관해 값이 같습니다.

> **교수님께**
> prior를 모든 시정촌에서 0.5로 바꾸면 전체 AUC가 0.855에서 0.602로(4개로 학습 기준 0.862에서 0.666으로) 크게 떨어집니다. 같은 값을 평균이나 학습으로 정해도 결과는 비슷합니다. 피해 통계만으로는 원인을 구분할 수 없고, 물리 기반 prior가 원인 구분의 핵심 단서임을 보여 줍니다.

4-2. 입력: 흔들림 강도 항 제거

확인하려는 것	흔들림에 의한 기본 피해를 분리해야 산사태 · 액상화 몫이 잘 갈리는가
바꾼 것	피해율 식에서 $\beta \cdot \log PGV$ 항을 뺌 (PGV를 1로 두어 $\log 1 = 0$). 아쓰마초 PGV 44.64가 모든 시정촌과 같은 값으로 취급됨

결과: 0.855에서 0.862로 +0.007 (4개로 학습 기준 +0.001). 산사태는 0.872에서 0.836으로 내려가고, 액상화는 0.850에서 0.871로 올라감.

해석: 빼도 정확도가 떨어지지 않음. 지진 전체의 흔들림 수준은 지진 절편 α_e가 이미 흡수하므로, 이 항이 맡는 것은 지진 안에서 시정촌마다 다른 흔들림뿐이라 효과가 작을 수 있음(추측). 산사태에는 도움이 되고 액상화에는 손해라 재해마다 방향이 반대. 초안의 "흔들림 강도로 원인 구분"은 정확도로는 뒷받침되지 않음.

> **교수님께**
> 흔들림 강도 항을 빼도 전체 AUC는 떨어지지 않았습니다(0.855에서 0.862). 산사태는 내려가고(0.872에서 0.836) 액상화는 올라 효과가 재해마다 다릅니다. 이 항은 정확도보다는 흔들림 피해와 후속 재난 피해를 나누는 해석(RQ3) 쪽 역할로 보는 게 맞을 것 같은데, 논문에서 어떻게 위치시킬지 여쭙고 싶습니다.

4-3. 구조: 음이항분포를 포아송분포로 교체

확인하려는 것	피해 건수의 과분산(C2)을 다뤄야 하는가
바꾼 것	피해 건수 분포를 포아송으로. 포아송은 분산 = 평균이라 과분산을 허용하지 않음. 구현: 우도 계산 부품을 포아송 log 확률($y \cdot \log \mu - \mu - \log y!$)로 바꿔 끼움

예시 (설명용 숫자): 어떤 시정촌의 기대 전파 건수가 $\mu = 100$이라고 할 때, 음이항($\phi = 5$)은 표준편차가 약 46이라 실제 200건도 "있을 법한 일"입니다. 포아송은 표준편차가 10이라 200건은 거의 불가능한 일로 취급되고, 모델은 이 큰 값을 설명하려고 숨은 재해 상태를 억지로 바꿉니다. 피해는 한 시정촌 안에서도 몰려서 나기 때문에 실제 자료에는 이런 큰 값이 흔합니다.

결과: 0.855에서 0.524로 −0.331 (4개로 학습 기준 −0.259). 액상화는 0.498로 무작위 수준.

해석: 가장 크게 떨어지는 설정. 과분산을 무시하면 큰 시정촌의 피해 건수에 끌려가 순위가 무너짐. C2의 직접 근거.

> **교수님께**
> 음이항분포를 포아송분포로 바꾸면 전체 AUC가 0.855에서 0.524로 가장 크게 떨어집니다. 피해 건수의 과분산을 다루는 것이 필수임을 보여 줍니다.

4-4. 구조: 노출 offset 제거

확인하려는 것	시정촌 규모를 노출로 정규화해야 하는가(C2)
바꾼 것	기대 피해 μ = E × λ 에서 E를 모두 1로. 아쓰마초(인구 4,838)와 인구가 수십 배인 도시를 같은 규모로 보는 셈

결과: 0.855에서 0.834로 −0.022 (4개로 학습 기준 −0.004). 산사태는 0.872에서 0.903으로 오르고, 액상화는 0.850에서 0.811로 내려감.

해석: 전체로는 작게 떨어짐. 액상화는 인구가 많은 도시에서 많이 나서, 규모를 보정하지 않으면 큰 도시 피해에 끌려가 손해. 산사태가 오른 것은 산사태 사전확률에 시정촌 크기 항(log k)이 이미 있어 규모 정보가 일부 대신 들어가기 때문일 수 있음(추측). 채점 수가 작은 조합은 크게 흔들림(후쿠시마 액상화 7곳이 0.000).

> **교수님께**
> 노출 offset(인명은 인구, 주택은 일반세대 수)을 빼면 전체 AUC가 0.855에서 0.834로 떨어집니다. 액상화에서 효과가 크고(0.850에서 0.811), 산사태는 prior에 시정촌 크기 항이 있어 영향이 작습니다.

초안 수정 필요: 초안의 "세대 수 노출 offset"은 실제로는 인명 피해에 인구, 주택 피해에 일반세대 수입니다.

4-5. 학습: 크로스이벤트 학습 대신 이벤트별 단독 학습

확인하려는 것	여러 지진에 걸쳐 파라미터를 공유하고 과거 라벨을 쓰는 것이 필요한가(C3)
바꾼 것	예측할 지진 하나의 자료로만 학습. 예) 홋카이도 회차: TRACE는 다른 지진 378행으로 학습, 단독 학습은 홋카이도 40행으로만 학습. 그 지진 정답은 평가에 쓰므로 학습에 쓸 수 없어 라벨 없이 피해 건수만으로 학습

결과: 0.855에서 0.841로 −0.014 (4개로 학습 기준 −0.021). 산사태는 0.872에서 0.880으로 조금 오르고, 액상화는 0.850에서 0.829로 내려감.

해석: 떨어지지만 작음. 단독 학습도 사전확률은 그대로 쓰는데, 4-1에서 보았듯 성능의 대부분이 사전확률에서 나옴. 이 설정은 "공유 학습"과 "과거 라벨 사용"을 한꺼번에 빼므로 둘 중 무엇이 기여하는지는 나눠 말할 수 없음. 크로스이벤트의 더 큰 장점은 새 지진에서 다시 학습하지 않아도 된다는 점(RQ2의 시간).

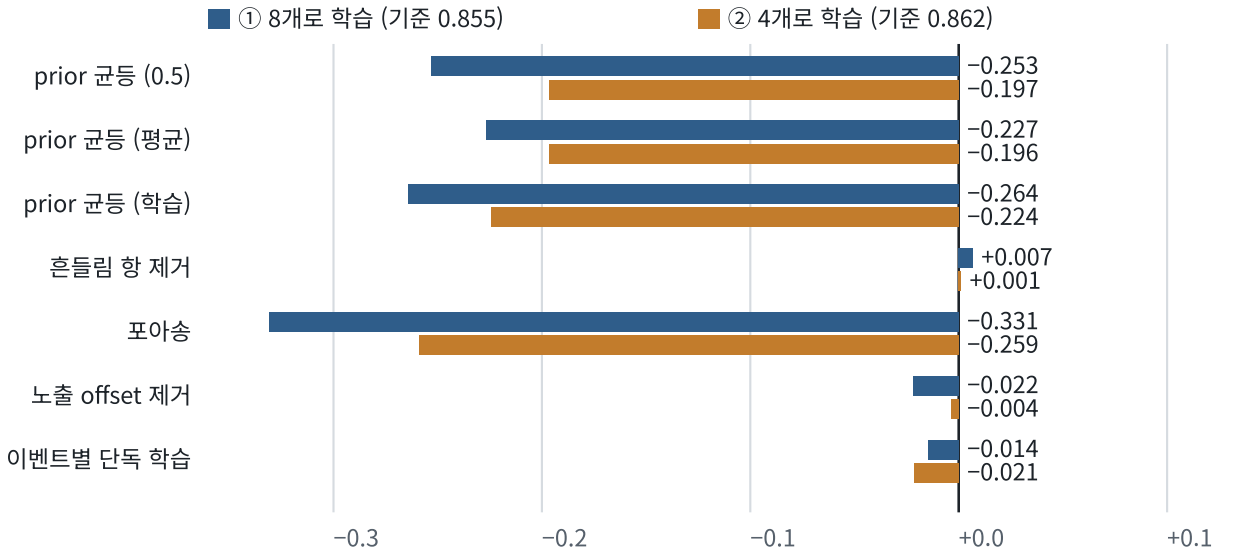
> **교수님께**
> 이벤트별 단독 학습(예측 지진 하나로만, 라벨 없이)으로 바꾸면 전체 AUC가 0.855에서 0.841로 소폭 떨어집니다. 크로스이벤트 학습의 정확도 기여는 작고, 주된 이점은 새 지진에서 재학습 없이 바로 추론할 수 있다는 점(RQ2)입니다.

5. 결과

5-1. 전체 결과 (지진 · 재해별 AUC를 채점 시정촌 수로 가중평균)

설정	① 8개로 학습, 5개 추론				② 4개로 학습, 5개 추론			
	전체	산사태	액상화	차이	전체	산사태	액상화	차이
TRACE (전체)	**0.855**	**0.872**	**0.850**	**기준**	**0.862**	**0.887**	**0.854**	**기준**
prior 균등 (0.5)	0.602	0.725	0.562	−0.253	0.666	0.762	0.634	−0.197
prior 균등 (평균)	0.629	0.718	0.600	−0.227	0.666	0.725	0.647	−0.196
prior 균등 (학습)	0.591	0.702	0.555	−0.264	0.638	0.688	0.622	−0.224
흔들림 항 제거	0.862	0.836	0.871	+0.007	0.863	0.864	0.863	+0.001
포아송	0.524	0.608	0.497	−0.331	0.604	0.432	0.659	−0.259
노출 offset 제거	0.834	0.902	0.811	−0.022	0.859	0.887	0.849	−0.004
이벤트별 단독 학습	0.841	0.879	0.829	−0.014	0.841	0.879	0.829	−0.021

5-2. 기준 대비 전체 AUC 변화 (DPM 있는 5개 지진 추론 · 채점)



5-3. 지진 · 재해별 AUC (① 8개로 학습, 5개 추론)

재해	지진	채점	TRACE	균등 (0.5)	균등 (평균)	균등 (학습)	흔들림 제거	포아송	노출 제거	단독 학습
액상화	2016 구마모토	40	0.950	0.636	0.725	0.616	0.985	0.726	0.896	0.937
액상화	2018 홋카이도	40	0.913	0.345	0.345	0.348	0.926	0.419	0.872	0.913
액상화	2021 후쿠시마	7	0.667	0.833	0.833	0.833	0.500	0.333	0.000	0.500
액상화	2024 노토반도	64	0.768	0.622	0.655	0.616	0.805	0.421	0.808	0.744
산사태	2016 구마모토	29	0.846	0.795	0.782	0.756	0.821	0.699	0.897	0.846
산사태	2018 오사카	7	1.000	0.700	0.700	0.700	0.800	0.300	1.000	1.000
산사태	2018 홋카이도	13	0.861	0.583	0.583	0.583	0.889	0.569	0.861	0.889

5-4. 지진 · 재해별 AUC (② 4개로 학습, 5개 추론)

재해	지진	채점	TRACE	균등 (0.5)	균등 (평균)	균등 (학습)	흔들림 제거	포아송	노출 제거	단독 학습
액상화	2016 구마모토	40	0.957	0.778	0.821	0.750	0.972	0.835	0.944	0.937
액상화	2018 홋카이도	40	0.918	0.373	0.361	0.368	0.923	0.402	0.908	0.913
액상화	2021 후쿠시마	7	0.667	0.833	0.833	0.833	0.500	0.333	0.167	0.500
액상화	2024 노토반도	64	0.770	0.686	0.696	0.676	0.797	0.746	0.828	0.744
산사태	2016 구마모토	29	0.859	0.821	0.782	0.731	0.821	0.372	0.872	0.846
산사태	2018 오사카	7	1.000	0.800	0.700	0.600	1.000	0.300	1.000	1.000
산사태	2018 홋카이도	13	0.889	0.611	0.611	0.639	0.889	0.639	0.861	0.889

정답이 한쪽뿐인 조합(산사태 후쿠시마 · 노토, 액상화 오사카)은 AUC를 낼 수 없어 표에 없습니다.

6. 정리

층위	설계	빼면 (① 8개로 학습)	결론
입력	물리 기반 prior	−0.23 ~ −0.26	핵심. 원인 구분(C1)의 단서
입력	흔들림 강도 항	+0.007	정확도 기여 없음. 해석(RQ3) 쪽 역할로 설명할지 결정 필요
구조	음이항분포	−0.331	핵심. 과분산 처리(C2) 필수
구조	노출 offset	−0.022	작게 기여 (주로 액상화)
학습	크로스이벤트 학습	−0.014	작게 기여. 주된 이점은 재학습 없는 추론(RQ2)

보고할 때 같이 말할 점

- 표본이 작습니다. 산사태 채점은 49곳(음성 9곳)뿐이고, 신뢰구간은 내지 않았습니다. 0.01 ~ 0.02 차이는 우연일 수 있습니다.
- 이벤트별 단독 학습은 "공유 학습"과 "과거 라벨 사용"을 한꺼번에 뺀 것입니다. 둘을 나누려면 "크로스이벤트 + 라벨 없음" 설정을 하나 더 실행하면 됩니다.
- 두 기준(8개로 학습 / 4개로 학습) 모두 같은 결론입니다. 4개로 학습 기준에서는 노출 offset(−0.004)과 흔들림 항(+0.001)의 차이가 더 작습니다.

7. 재현 방법

- 스크립트: 저장소 minji1217/pilotA-minji 브랜치 claude/dazzling-babbage-8c6yd4의 `pilota_ablation/run_ablation.py`, `score_ablation.py`
- 실행: `python run_ablation.py <pilotA 폴더> [--dpm5] [설정 ...]` 후 `python score_ablation.py <pilotA 폴더> 결과.csv [--dpm5]`
- 설정 이름: full, uniform_half(0.5), uniform_prior(평균), uniform_learned(학습), no_pgv, poisson, no_exposure, per_event
- 결과 파일: `pilota_ablation/ablation_result.csv`, `ablation_result_dpm5.csv`, 각각 `_지진별.csv`
- 실행 환경: 클라우드 가상 컴퓨터, Python 3.13.16, PyTorch 2.14.1, NumPy 2.5.3, pandas 3.0.5. 설정 하나(LOEO 9번)에 약 2분